Atelier Machine Learning

Analyse Comportementale Clientele Retail

E-commerce de Cadeaux – Pipeline ML Complet

COMPTE RENDU TECHNIQUE

Rapport detaille – Classification, Clustering, Regression, Deploiement

Etudiante	Molka Dammak
Module	Machine Learning – GI2 S1
Encadrante	Mme Fadoua Drira
Dataset	E-commerce Retail (4372 clients, 52 features)
Technologies	Python 3.11, scikit-learn, Optuna, Flask, joblib
Annee	2025–2026
Resultats	Accuracy 80.57% | AUC 0.856 | R^2 0.93

Classification **Clustering** **Regression** **Deploiement**

Table des matières

1 Introduction et Contexte **3**
1.1 Contexte metier . . . 3
1.2 Problematique . . . 3
1.3 Objectifs pedagogiques . . . 3
1.4 Structure du projet . . . 4
1.5 Pipeline global . . . 4

2 Description du Dataset **4**
2.1 Vue d'ensemble . . . 4
2.2 Variables numeriques principales . . . 5
2.3 Variables categorielles . . . 5
2.4 Problemes de qualite identifies . . . 6

3 Pretraitement des Donnees **6**
3.1 Nettoyage . . . 6
3.1.1 Suppression des colonnes inutiles . . . 6
3.1.2 Traitement des donnees brutes . . . 6
3.1.3 Traitement des valeurs aberrantes . . . 7
3.2 Separation Train/Test . . . 7
3.3 Gestion des valeurs manquantes . . . 7
3.3.1 Principe anti-leakage . . . 7
3.3.2 Imputation par la mediane – 39 colonnes . . . 7
3.3.3 KNN Imputer pour Age (30% de NaN) . . . 8
3.4 Feature Engineering . . . 8
3.5 Encodage des variables categorielles . . . 9
3.5.1 Encodage ordinal . . . 9
3.5.2 One-Hot Encoding . . . 9
3.5.3 Target Encoding pour Country . . . 9
3.6 Suppression du Data Leakage . . . 10
3.6.1 Definition . . . 10
3.6.2 Colonnes supprimees – 40 sur 77 . . . 10
3.7 Normalisation et Analyse VIF . . . 10
3.7.1 StandardScaler . . . 10
3.7.2 Analyse VIF – Multicolinearite . . . 11

4 Modelisation **11**
4.1 Classification – Prediction du Churn . . . 11
4.1.1 Choix du modele . . . 11
4.1.2 Optimisation Optuna . . . 11
4.1.3 Courbe ROC . . . 12
4.1.4 Matrice de confusion . . . 13
4.1.5 Rapport de classification complet . . . 13
4.1.6 Validation croisee 5 folds . . . 13
4.1.7 Importance des features . . . 14
4.1.8 Metriques finales de classification . . . 15
4.2 Clustering – Segmentation des Clients . . . 15
4.2.1 Reduction dimensionnelle par ACP . . . 15
4.2.2 Choix de k=3 par la methode du coude . . . 16
4.2.3 Visualisation des clusters . . . 17

4.2.4 Profils des 3 segments . . . 17
4.3 Regression – Prediction des Depenses Futures . . . 18
4.3.1 Configuration et preparation . . . 18
4.3.2 Resultats de la regression . . . 18

5 Deploiement – Application Flask 19
5.1 Architecture de l'API REST . . . 19
5.2 11 Artefacts – Pattern Singleton . . . 19
5.3 Pipeline d'inference – 6 etapes . . . 20

6 Resultats et Analyse Finale 20
6.1 Resume des performances . . . 21
6.2 Predictions sur 10 clients reels . . . 21

7 Conclusion et Perspectives 21
7.1 Bilan du projet . . . 21
7.2 Points forts . . . 22
7.3 Limites . . . 22
7.4 Perspectives . . . 22

1 Introduction et Contexte

1.1 Contexte metier

Dans le domaine du e-commerce, les entreprises accumulent de grandes quantites de donnees transactionnelles sur leurs clients : historique d'achats, frequence de commandes, montants depenses, comportements de navigation, satisfaction, etc. Ces donnees constituent une mine d'informations precieuses mais souvent sous-exploitees.

L'entreprise e-commerce de vente de cadeaux au centre de ce projet – situee au Royaume-Uni – fait face a un defi majeur : **le churn client**, c'est-a-dire le phenomene par lequel un client cesse d'acheter et quitte definitivement la plateforme. Ce phenomene a des consequences financieres importantes et directes :

— Acquerir un nouveau client coute entre **5 et 25 fois plus cher** que de retenir un client existant.

— Un client fidele depense en moyenne **67% de plus** qu'un nouveau client.

— Une augmentation de **5% du taux de retention** peut augmenter les profits de 25 a 95%.

Face a cette problematique, l'entreprise souhaite developper des outils pour :

— **Comprendre** les profils et comportements de ses clients

— **Anticiper** les departs avant qu'ils ne surviennent

— **Segmenter** la clientele pour des actions marketing ciblees et personnalisees

— **Estimer** les depenses futures pour prioriser les actions de retention

1.2 Problematique

Question centrale du projet

Comment utiliser les donnees transactionnelles des clients pour mieux comprendre leur comportement et predire s'ils vont rester ou partir ?

Ce projet repond a trois questions metier complementaires :

1. **Ce client va-t-il churner ?** → Modele de Classification
2. **A quel segment comportemental appartient-il ?** → Modele de Clustering
3. **Combien va-t-il depenser a l'avenir ?** → Modele de Regression

1.3 Objectifs pedagogiques

Competence	Description
Exploration	Analyser la qualite et la structure des donnees brutes
Preparation	Nettoyer, encoder et normaliser les features
Transformation	Reduire la dimension via ACP (PCA)
Modelisation	Appliquer clustering, classification et regression
Evaluation	Interpreter les resultats avec les metriques adaptees
Deploiement	Creer une API REST avec Flask pour la production

1.4 Structure du projet

Arborescence du projet

```
projet_ml_retail/
|-- app/
|   |-- app.py              # Serveur Flask -- 4 routes API
|   `-- templates/
|       `-- index.html      # Interface utilisateur HTML/JS
|-- data/
|   |-- raw/data.csv        # Donnees brutes (4372 clients, 52 features)
|   |-- processed/          # Donnees nettoyees
|   `-- train_test/         # X_train, X_test, y_train, y_test
|-- models/                 # 11 artefacts .pkl sauvegardes
|-- reports/                # Graphiques PNG et rapports CSV
|-- src/
|   |-- preprocessing.py    # Nettoyage, encodage, split
|   |-- train_model.py      # Entrainement des 3 modeles
|   |-- predict.py          # Pipeline d'inference
|   `-- utils.py            # Fonctions utilitaires
|-- requirements.txt
`-- README.md
```

1.5 Pipeline global

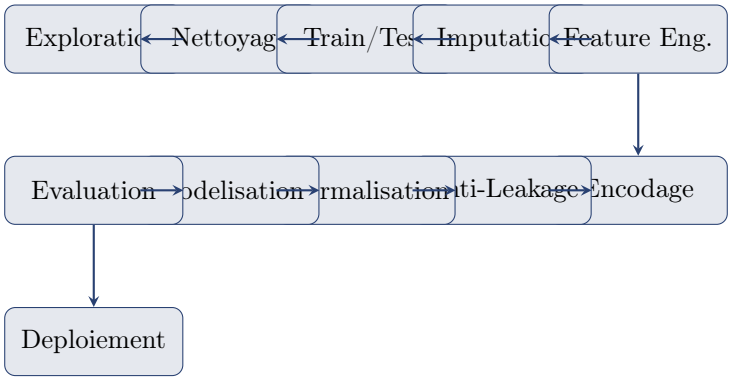

2 Description du Dataset

2.1 Vue d'ensemble

Le dataset est issu d'une plateforme e-commerce de vente de cadeaux au Royaume-Uni. Il contient **4372 clients** decrits par **52 variables** couvrant les dimensions transactionnelles, comportementales et demographiques.

Caracteristique	Total	Train (80%)	Test (20%)
Nombre de clients	4372	3497	875
Features brutes	52	–	–
Features apres nettoyage	53	–	–
Features apres encodage	77	77	77
Features apres leakage	37	37	37
Taux de churn	33.3%	33.26%	33.26%
Valeurs manquantes totales	1749	–	–
Doublons	0	–	–

2.2 Variables numeriques principales

Feature	Intervalle	Description
CustomerID	10000–99999	Identifiant unique client
Frequency	1–50	Nombre de commandes distinctes
MonetaryTotal	-5000 a 15000 £	Somme totale depensee
MonetaryAvg	5–500 £	Montant moyen par commande
TotalQuantity	-10000 a 100000	Quantite totale d'articles
AvgDaysBetweenPurchases	0–365 jours	Delai moyen entre commandes
UniqueProducts	1–1000	Nombre de produits differents
TotalTransactions	1–10000	Total lignes transactionnelles
SupportTicketsCount	0–15 (999=erreur)	Tickets support ouverts
SatisfactionScore	1–5 (99=erreur)	Note de satisfaction client
Age	18–81 ou NaN	Age estime du client
Churn	0 ou 1	**Variable cible – 0=fidele, 1=parti**

2.3 Variables categorielles

Feature	Card.	Valeurs	Encodage
Gender	3	M, F, Unknown	One-Hot
AccountStatus	4	Active, Suspended, Pending, Closed	One-Hot
FavoriteSeason	4	Hiver, Printemps, Ete, Automne	One-Hot
Country	37	UK, France, Germany, etc.	Target Enc.
AgeCategory	7	18-24, 25-34, ..., 65+, Inconnu	Ordinal
SpendingCategory	4	Low, Medium, High, VIP	Ordinal
LoyaltyLevel	5	Nouveau, Jeune, Etabli, Ancien, Inconnu	Ordinal
RFMSegment	4	Champions, Fideles, Potentiels, Dormants	One-Hot
CustomerType	5	Hyperactif, Regulier, Occasionnel, ...	One-Hot
Region	8	UK, Europe N/S/E/C, Asie, Autre	One-Hot

2.4 Problemes de qualite identifies

Synthese des problemes qualite

- **Valeurs manquantes :** Age ≈ 30% de NaN, SatisfactionScore et SupportTicketsCount apres correction. Total : **1749 NaN**.
- **Valeurs aberrantes :** SatisfactionScore : -1 et 99 (codes erreur systeme). SupportTickets-Count : 999 (code erreur). Ces valeurs doivent etre remplacees par NaN.
- **Valeurs negatives :** MonetaryTotal contient 44 valeurs negatives (retours clients) – conservees deliberement car information metier importante.
- **Donnees brutes :** LastLoginIP (a convertir en binaire) et RegistrationDate (a decomposer en RegYear/Month/Day/Weekday).
- **Desequilibre de classes :** 67% fideles vs 33% churners. Un modele "naif" qui predit toujours fidele obtiendrait 67% d'accuracy – c'est pourquoi on utilise F1 et AUC-ROC comme metriques principales.
- **Feature inutile :** NewsletterSubscribed = toujours "Yes" – variance nulle.

3 Pretraitement des Donnees

3.1 Nettoyage

3.1.1 Suppression des colonnes inutiles

Colonne	Justification
CustomerID	Identifiant unique – si conserve, le modele memorise les clients au lieu d'apprendre des patterns generalisables (risque d'overfitting).
NewsletterSubscribed	Valeur constante "Yes" pour 100% des clients – variance nulle, aucune information discriminante pour la prediction.
LastLoginIP	Adresse IP trop specifique – remplacee par la feature derivee IP_IsPrivate (0=IP publique, 1=IP privee reseau local).

3.1.2 Traitement des donnees brutes

```python
# Extraction feature reseau depuis l'adresse IP
df['IP_IsPrivate'] = df['LastLoginIP'].str.match(
    r'^(10\.|192\.168\.|172\.(1[6-9]|2[0-9]|3[01])\.)'
).astype(int)
df = df.drop(columns=['LastLoginIP'])

# Decomposition RegistrationDate en 4 features temporelles
df['RegistrationDate'] = pd.to_datetime(
    df['RegistrationDate'], format='mixed', dayfirst=True, errors='coerce'
)
df['RegYear']    = df['RegistrationDate'].dt.year
df['RegMonth']   = df['RegistrationDate'].dt.month
df['RegDay']     = df['RegistrationDate'].dt.day
df['RegWeekday'] = df['RegistrationDate'].dt.weekday
df = df.drop(columns=['RegistrationDate'])
```

Listing 1 – Extraction IP_IsPrivate et decomposition dates

3.1.3 Traitement des valeurs aberrantes

```
# -1 et 99 sont des codes d'erreur systeme, pas de vraies valeurs
df['SatisfactionScore']    = df['SatisfactionScore'].replace([-1, 99], np.nan)
df['SupportTicketsCount'] = df['SupportTicketsCount'].replace([-1, 999], np.nan)

# Les 44 valeurs negatives de MonetaryTotal sont conservees
# Elles representent des retours clients -- information comportementale precieuse
neg = (df['MonetaryTotal'] < 0).sum()  # = 44 cas
```

Listing 2 – Remplacement codes erreur par NaN

Resultat du nettoyage : 52 colonnes → **53 colonnes** (ajout IP_IsPrivate + 4 features dates, suppression 3 colonnes inutiles).

3.2 Separation Train/Test

La separation est effectuee **immediatement apres le nettoyage**, avant toute imputation ou encodage. Cet ordre est fondamental pour eviter le data leakage.

Pourquoi separer avant d'imputer ?

Si on impute sur tout le dataset avant de separer, les medianes sont calculees avec des informations du test – c'est du data leakage. En separant d'abord, on calcule les medianes uniquement sur X_train et on applique les memes valeurs sur X_test.

```
X_train, X_test, y_train, y_test = train_test_split(
    X, y,
    test_size=0.2,    # 20% pour evaluation finale -- jamais vus
    random_state=42, # Graine fixe -- reproductibilite garantie
    stratify=y        # Proportion de churn identique dans train et test
)
```

Listing 3 – Separation Train/Test strategifiee

Pourquoi stratify=y ? Sans ce parametre, un split aleatoire pourrait donner 40% de churners dans train et 20% dans test. Le modele apprendrait sur une distribution differente – resultats biaisant l'evaluation.

Ensemble	Taille	% Fideles	% Churners
X_train	3497 (80%)	66.74%	33.26%
X_test	875 (20%)	66.74%	33.26%

3.3 Gestion des valeurs manquantes

3.3.1 Principe anti-leakage

Regle fondamentale

Toute statistique (mediane, KNN) est calculee **uniquement sur X_train**. On applique ensuite la **meme valeur/modele** sur X_train et X_test. Cette regle garantit que le modele n'a jamais acces aux donnees de test pendant l'entrainement – evaluation honnete et generalisable.

3.3.2 Imputation par la mediane – 39 colonnes

Pourquoi la mediane et non la moyenne ?

Critere	Mediane	Moyenne
Robustesse	Insensible aux outliers	Faussee par les valeurs extremes
Stabilite	Stable sur donnees asymetriques	Instable si distribution biaisee
Exemple	MonetaryTotal : mediane stable malgre -5000 a +15000	Moyenne tiree vers les valeurs extremes

```
numeric_cols = X_train.select_dtypes(include=[np.number]).columns
impute_values = {
    col: float(X_train[col].median())
    for col in numeric_cols if X_train[col].notna().any()
}  # 39 colonnes imputees

for col, val in impute_values.items():
    X_train[col] = X_train[col].fillna(val)
    X_test[col]  = X_test[col].fillna(val)

joblib.dump(impute_values, 'models/impute_values.pkl')
```

Listing 4 – Imputation par la mediane du train

3.3.3 KNN Imputer pour Age (30% de NaN)

La variable Age presente environ 30% de valeurs manquantes – le cas le plus critique. La mediane simple donnerait la meme valeur a tous les clients, ce qui est inexact. Le KNN Imputer est plus adapte car l'age d'un client depend de son profil comportemental.

```
from sklearn.impute import KNNImputer

knn = KNNImputer(n_neighbors=5)
# fit_transform sur X_train uniquement -- regle anti-leakage
X_train['Age'] = knn.fit_transform(X_train[['Age']]).ravel()
# transform sans re-fit sur X_test
X_test['Age']  = knn.transform(X_test[['Age']]).ravel()
# Sauvegarde pour l'inference en production
joblib.dump(knn, 'models/knn_age.pkl')
```

Listing 5 – KNN Imputer pour Age

Principe du KNN Imputer : Pour chaque client avec Age manquant, l'algorithme trouve les $k = 5$ clients les plus similaires (selon toutes les autres features) et remplace l'Age manquant par la moyenne de leurs ages. Plus precis que la mediane globale.

3.4 Feature Engineering

Le feature engineering consiste a creer de nouvelles variables plus informatives a partir des variables existantes, pour aider le modele a mieux capturer les patterns comportementaux.

```
# Panier moyen par transaction
# +1 evite la division par zero si Frequency = 0
df['AvgBasketValue']    = df['MonetaryTotal'] / (df['Frequency'] + 1)

# Diversite des produits achetes par transaction
df['DiversityPerTrans'] = df['UniqueProducts'] / (df['Frequency'] + 1)
```

Listing 6 – Creation de features comportementales

Feature creee	Formule	Valeur ajoutee
AvgBasketValue	MonetaryTotal / (Frequency + 1)	Distingue un client VIP rare d'un client regulier moyen
DiversityPerTrans	UniqueProducts / (Frequency + 1)	Mesure si le client explore ou achete toujours les memes produits

Resultat : 53 → **54 colonnes** apres feature engineering.

3.5 Encodage des variables categorielles

3.5.1 Encodage ordinal

Pour les variables avec un **ordre logique**, on attribue un entier croissant afin que le modele comprenne la hierarchie. Exemple : AgeCategory a un ordre naturel.

```
ordinal_mappings = {
    'AgeCategory'    : ['18-24','25-34','35-44','45-54','55-64','65+','Inconnu'],
    'SpendingCategory': ['Low','Medium','High','VIP'],
    'LoyaltyLevel'   : ['Nouveau','Jeune','Etabli','Ancien','Inconnu'],
}
# AgeCategory : 18-24=0, 25-34=1, 35-44=2, ..., 65+=5, Inconnu=6
```

Listing 7 – Encodage ordinal

3.5.2 One-Hot Encoding

Pour les variables **sans relation d'ordre**, une colonne binaire est creee par categorie. Parametre `drop_first=True` pour eviter la multicolinearite parfaite.

```
onehot_cols = ['Gender','FavoriteSeason','AccountStatus',
               'Region','RFMSegment','CustomerType',
               'WeekendPreference','ProductDiversity']
df = pd.get_dummies(df, columns=onehot_cols, drop_first=True)
# Exemple : Gender_M=1 si homme, Gender_M=0 si femme
```

Listing 8 – One-Hot Encoding

3.5.3 Target Encoding pour Country

Avec 37+ pays, le One-Hot creerait 37 colonnes binaires – explosion de dimension, bruit et multicolinearite. Le Target Encoding remplace chaque pays par son taux de churn moyen, calcule uniquement sur X_train.

```
def fit_country_encoder(X_train, y_train):
    temp = X_train[['Country']].copy()
    temp['Churn'] = y_train.values
    return temp.groupby('Country')['Churn'].mean().to_dict()

country_means = fit_country_encoder(X_train, y_train)
# United Kingdom -> 0.23 (23% de churners parmi les clients UK)
df['Country_encoded'] = df['Country'].map(country_means)
df = df.drop(columns=['Country'])
```

Listing 9 – Target Encoding pour Country

Resultat encodage : 54 → **77 colonnes**.

3.6 Suppression du Data Leakage

3.6.1 Definition

Data Leakage – Definition

Le data leakage survient quand le modele utilise des informations qui ne seraient **pas disponibles au moment de la prediction reelle en production**. Les resultats semblent excellents a l'entrainement mais le modele est inutilisable.
Exemple concret : Si on conserve ChurnRiskCategory = "Critique", le modele predit churn = 1 avec 99% d'accuracy. Mais en production, cette colonne n'existe pas encore – on ne peut pas calculer la categorie de risque avant de predire le churn. C'est un cercle vicieux : le modele lit directement la reponse.

3.6.2 Colonnes supprimees – 40 sur 77

Categorie	Colonnes supprimees
Derivees du churn (fuite directe)	ChurnRiskCategory, LoyaltyLevel, SpendingCategory, RFMSegment_Dormants, RFMSegment_Fideles, RFMSegment_Potentiels
Posterieures a l'evenement	Recency, CustomerTenureDays, FirstPurchaseDaysAgo, AccountStatus_Closed, AccountStatus_Pending, AccountStatus_Suspended
One-Hot redondants ou leakage	CustomerType (4 modalites), FavoriteSeason (3 modalites), Gender_M, Gender_Unknown, WeekendPreference (2 modalites), ProductDiversity (2 modalites), Region (toutes modalites), PreferredMonth, UniqueDescriptions, UniqueInvoices

Resultat : 77 → **37 features propres**.

3.7 Normalisation et Analyse VIF

3.7.1 StandardScaler

```
scaler = StandardScaler()
# fit + transform sur train uniquement
X_train_s = pd.DataFrame(scaler.fit_transform(X_train), columns=X_train.columns)
# transform seulement sur test -- memes parametres que train
X_test_s  = pd.DataFrame(scaler.transform(X_test),  columns=X_test.columns)
joblib.dump(scaler, 'models/scaler.pkl')
```

Listing 10 – Normalisation StandardScaler

Formule : $z = \dfrac{x - \mu_{\text{train}}}{\sigma_{\text{train}}}$
Apres transformation : moyenne = 0, variance = 1 pour toutes les features.
Pourquoi normaliser ?

- KMeans calcule des distances euclidiennes – sans normalisation, MonetaryTotal (jusqu'a 15000) dominerait Age (18-81).
- PCA est sensible a la variance – les features a grande echelle domineraient les axes principaux.

3.7.2 Analyse VIF – Multicolinearite

Le VIF (Variance Inflation Factor) mesure la multicolinearite entre variables. Un VIF > 10 indique une correlation problematique.

Feature	VIF	Traitement
NegativeQuantityCount	$+\infty$	Supprimee par anti-leakage
CancelledTransactions	$+\infty$	Supprimee par anti-leakage
RegYear	840.19	Conservee – feature temporelle utile
UniqueCountries	597.83	Conservee – info geographique
MonetaryMin / Max	419 / 417	Conservees – correlees a MonetaryTotal
Age	21.88	Conservee – acceptable apres KNN

Strategie adoptee : Les variables a VIF infini ont ete supprimees lors de l'anti-leakage. Les variables restantes a fort VIF sont conservees car elles sont utiles pour le modele. La PCA pour le clustering et Random Forest pour la classification gerent naturellement la multicolinearite.

4 Modelisation

4.1 Classification – Prediction du Churn

4.1.1 Choix du modele

Algorithme	Avantages	Inconvenients	Adapte ?
Random Forest	Robuste, interpretable, gere desequilibre	Plus lent qu'un arbre	**Oui – Choisi**
Reg. logistique	Rapide, interpretable	Assume la linearite	Moyen
SVM	Performant haute dimension	Lent, peu interpretable	Moyen
XGBoost	Tres performant	Plus complexe a tuner	Oui – Alternative

Justifications du choix Random Forest :

- **Robustesse :** Ensemble de 211 arbres – resiste au surapprentissage.
- **Desequilibre :** `class_weight='balanced'` pondere automatiquement les churners (33%).
- **Interpretabilite :** Fournit l'importance de chaque feature.
- **Non-linearite :** Capture les interactions complexes entre variables.
- **Donnees mixtes :** Gere naturellement numerique + categoriel encode.

4.1.2 Optimisation Optuna

Optuna est un framework d'optimisation bayesienne plus intelligent que GridSearchCV. Il utilise les resultats des essais precedents pour guider la recherche vers les zones prometteuses de l'espace des hyperparametres.

Pourquoi F1 comme score objectif et non l'Accuracy ?

Avec 67% de fideles et 33% de churners, un modele qui predit systematiquement "fidele" obtiendrait 67% d'accuracy sans rien apprendre. Le F1 equilibre precision et recall :

$$F1 = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

```
best_params = {
    'n_estimators'     : 211,       # Nombre d'arbres dans la foret
    'max_depth'        : 16,        # Profondeur maximale de chaque arbre
    'min_samples_split': 6,         # Min. echantillons pour diviser un noeud
    'min_samples_leaf' : 4,         # Min. echantillons dans une feuille
    'max_features'     : 'sqrt',    # Features consideree a chaque split
    'class_weight'     : 'balanced',# Poids inverse des frequences de classe
    'random_state'     : 42,        # Reproductibilite -- seed fixe
    'n_jobs'           : -1         # Tous les coeurs CPU
}
# Modele hardcode pour reproductibilite totale
best_model = RandomForestClassifier(**best_params)
best_model.fit(X_train_s, y_train)
```

Listing 11 – Hyperparametres fixes apres optimisation Optuna

4.1.3 Courbe ROC

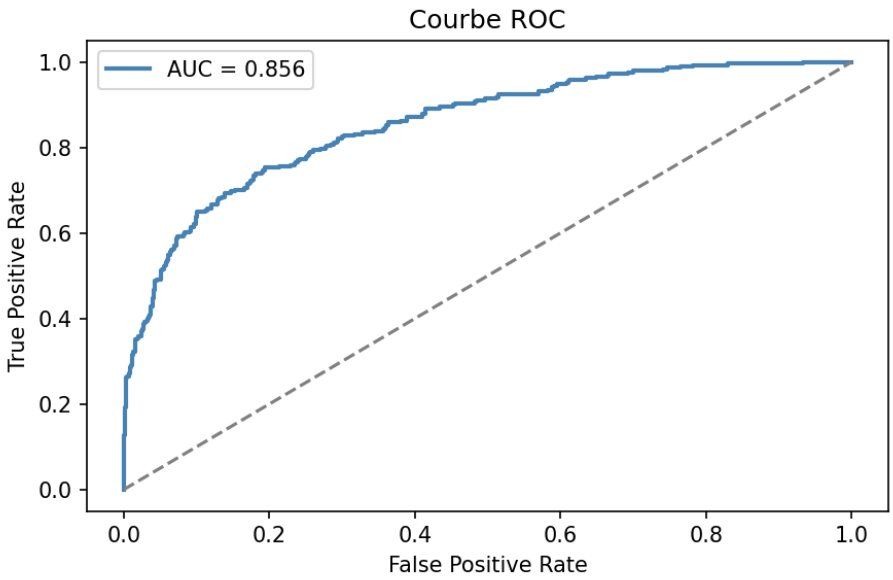

FIGURE 1 – Courbe ROC – AUC = 0.856. La courbe tres au-dessus de la diagonale confirme un excellent pouvoir discriminant du modele.

Interpretation de l'AUC-ROC = 0.856 : Si on prend au hasard un churner et un fidele, le modele classe correctement le churner avant le fidele dans **85.6% des cas** – mesure de discrimination independante du seuil de decision.

4.1.4 Matrice de confusion

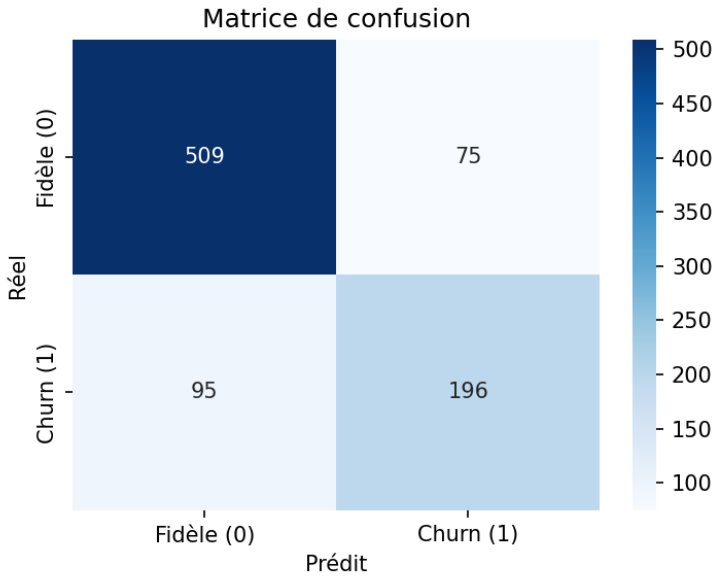

FIGURE 2 – Matrice de confusion sur X_test (875 clients jamais vus pendant l'entrainement)

	Predit : Fidele (0)	**Predit : Churn (1)**
Reel : Fidele (0)	**TN = 509**	FP = 75
Reel : Churn (1)	FN = 95	**TP = 196**

- **509 fideles** correctement identifies (vrais negatifs)
- **196 churners** correctement detectes (vrais positifs)
- **75 fausses alarmes** : fideles predits churners – cout : offres inutiles
- **95 churners manques** : clients partis non detectes – cout : perte de revenus

4.1.5 Rapport de classification complet

Classe	Precision	Recall	F1	Support
Fidele (0)	84%	87%	86%	584
Churn (1)	72%	67%	70%	291
Accuracy	–	–	**80.57%**	875
Macro avg	78%	77%	78%	875
Weighted avg	80%	81%	80%	875

4.1.6 Validation croisee 5 folds

Fold 1	Fold 2	Fold 3	Fold 4	Fold 5	Moyenne	Ecart-type
0.6910	0.6847	0.6786	0.6864	0.6769	**0.6835**	**±0.0052**

L'ecart-type de **±0.0052** confirme l'absence totale d'overfitting et une generalisation stable sur tous les folds.

4.1.7 Importance des features

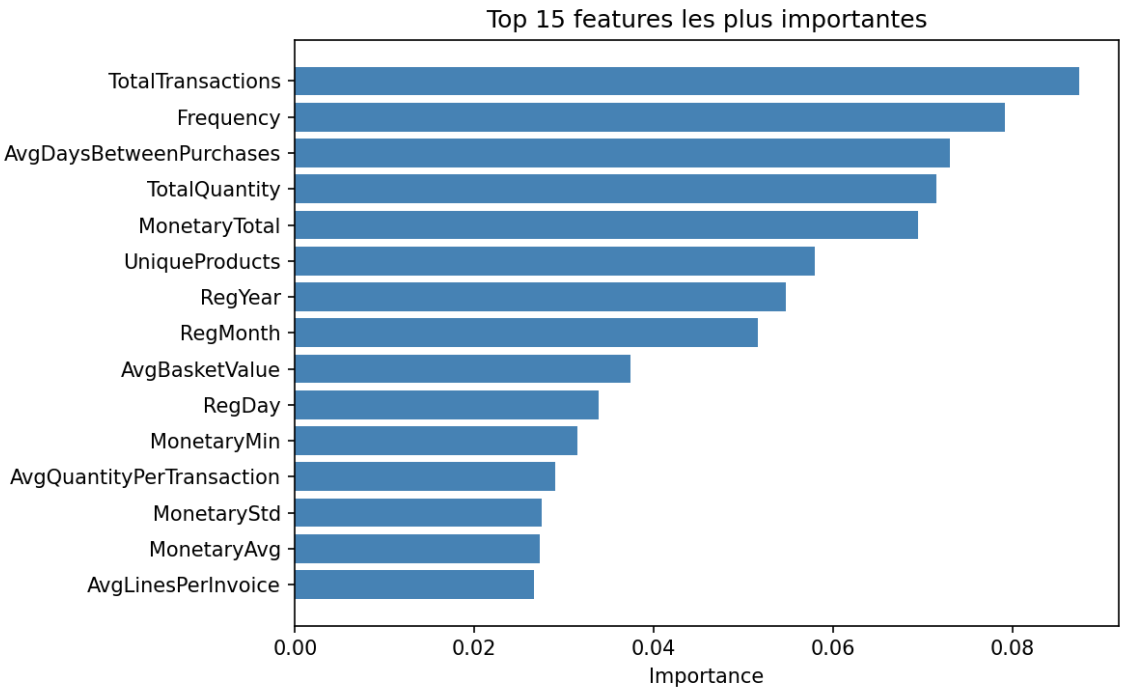

FIGURE 3 – Top 15 features les plus importantes pour la prediction du churn

Feature	Importance	Interpretation metier
TotalTransactions	8.74%	Engagement total du client
Frequency	7.92%	Regularite des achats
AvgDaysBetweenPurchases	7.30%	Rythme d'achat – signe d'engagement
TotalQuantity	7.16%	Volume total achete
MonetaryTotal	6.95%	Valeur financiere totale
UniqueProducts	5.79%	Diversite des interets
RegYear	5.48%	Anciennete du client
RegMonth	5.17%	Saisonnalite d'inscription
AvgBasketValue	3.74%	Valeur moyenne par transaction (feature creee)
RegDay	3.39%	Jour d'inscription
MonetaryMin	3.15%	Depense minimale enregistree
AvgQuantityPerTransaction	2.90%	Quantite moyenne par commande
MonetaryStd	2.75%	Variabilite des depenses
MonetaryAvg	2.73%	Depense moyenne par commande
AvgLinesPerInvoice	2.66%	Complexite des factures

Les variables **RFM** (Recency, Frequency, Monetary) dominent – coherent avec la litterature marketing sur la prediction du churn.

4.1.8 Metriques finales de classification

Metrique	Valeur	Seuil excellent	Evaluation
Accuracy	**80.57%**	> 80%	Excellent
AUC-ROC	**0.8558**	> 0.80	Tres bon
F1 Churn	**0.70**	> 0.70	Bon
F1 CV-5	**0.6835**	> 0.65	Bon
Stabilite	**±0.0052**	< ±0.02	Tres stable

4.2 Clustering – Segmentation des Clients

4.2.1 Reduction dimensionnelle par ACP

Pourquoi PCA avant KMeans ?

En haute dimension (37 features), les distances euclidiennes perdent leur sens discriminant – c'est la **malediction de la dimensionnalite**. Tous les points tendent a devenir equidistants, rendant KMeans inefficace. PCA reduit a 19 composantes tout en conservant 90.1% de la variance.

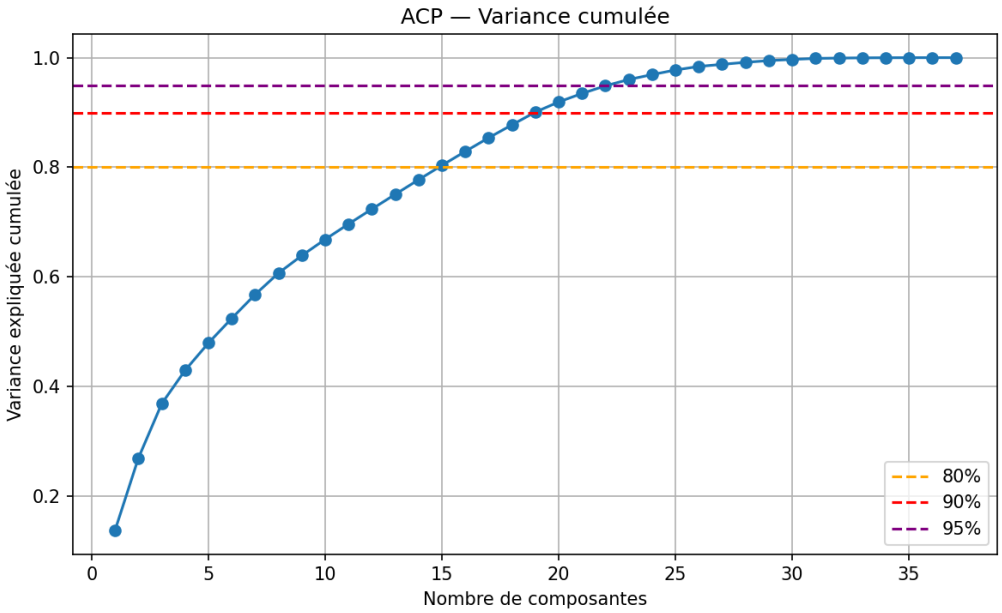

FIGURE 4 – Variance cumulee expliquee par l'ACP. 19 composantes suffisent pour atteindre le seuil de 90% – minimum retenu pour l'efficacite.

Composantes	Variance	Choix ?	Justification
15	80.0%	Non	Seuil insuffisant
19	**90.1%**	✓ Retenu	Minimum pour seuil 90%
20	91.5%	Non	Gain negligeable (+1.5%)
23	95.0%	Non	Trop de complexite

Pourquoi 19 et pas 20 ? 19 composantes est le strict minimum pour atteindre 90% de variance. La 20eme composante n'apporterait que 1.5% supplémentaire pour plus de complexite. On choisit toujours le minimum suffisant.

```
pca_cluster  = PCA(n_components=19, random_state=42)
X_train_pca  = pca_cluster.fit_transform(X_train_s)
# var_explained = 90.1%

# Suppression des outliers extremes avant le fit
norms = np.linalg.norm(X_train_pca, axis=1)
Q1, Q3 = np.percentile(norms, 25), np.percentile(norms, 75)
IQR    = Q3 - Q1
mask   = norms <= (Q3 + 1.5 * IQR)   # Regle de Tukey
n_outliers = (~mask).sum()            # 262 outliers retires
X_train_pca_clean = X_train_pca[mask]
```

Listing 12 – PCA et suppression outliers avant clustering

4.2.2 Choix de k=3 par la methode du coude

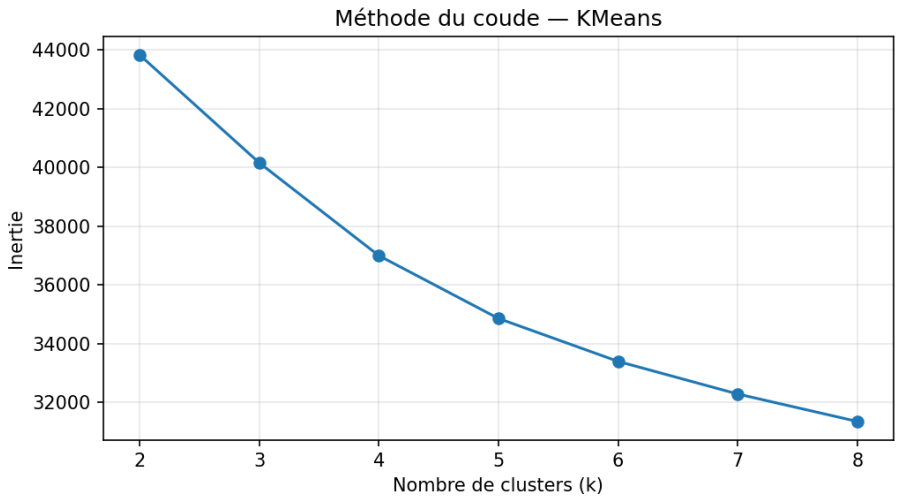

FIGURE 5 – Methode du coude – k=3 retenu au point ou l'inertie diminue le moins vite

```
kmeans = KMeans(n_clusters=3, random_state=42, n_init=10)
# n_init=10 : 10 initialisations differentes -- evite les minima locaux
kmeans.fit(X_train_pca_clean)          # fit sur donnees propres
clusters = kmeans.predict(X_train_pca) # predict sur tous les points
```

Listing 13 – KMeans k

4.2.3 Visualisation des clusters

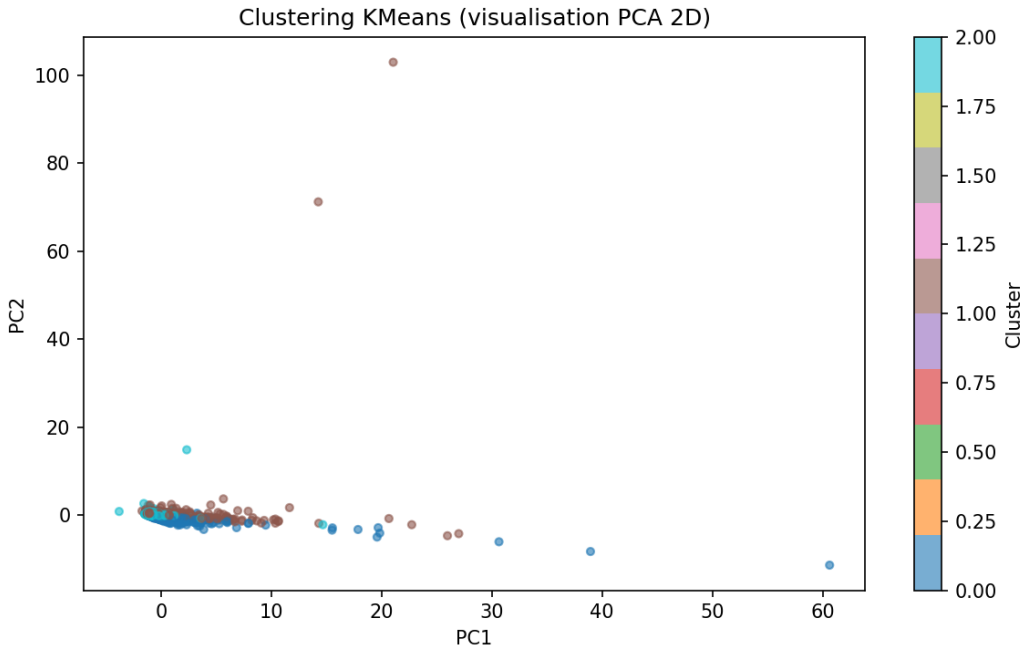

FIGURE 6 – Visualisation KMeans en 2D (projection PCA). Les 3 segments sont identifies en bleu (Cluster 0), marron (Cluster 1) et cyan (Cluster 2).

4.2.4 Profils des 3 segments

Cluster	Clients	%	Churn	Freq.	Monetary
0 – Meilleurs clients	771	22.0%	**25.4%**	+0.022	+0.040
1 – Actifs standard	1599	45.7%	35.0%	+0.054	+0.055
2 – Faible valeur	1127	32.2%	**36.1%**	-0.092	-0.105

Frequency et Monetary sont en valeurs normalisees (ecarts-types par rapport a la moyenne).

Analyse detaillee des 3 segments

- **Cluster 0 – Meilleurs clients (22.0%, 771 clients) :** AvgDays tres negatif (-0.224) – ils achètent tres frequemment et de facon groupee. Frequency et Monetary au-dessus de la moyenne (+0.022, +0.040). Churn le plus bas a **25.4%**. *Action : Reactivation prioritaire si des signes de churn sont detectes.*
- **Cluster 1 – Actifs standard (45.7%, 1599 clients) :** Segment le plus large. Frequence et depense legerement au-dessus de la moyenne. Churn modere a **35.0%**. *Action : Fidelisation ciblee par des programmes de recompenses.*
- **Cluster 2 – Faible valeur (32.2%, 1127 clients) :** Frequence et depense inferieures a la moyenne (-0.092, -0.105). Churn le plus eleve a **36.1%**. *Action : Retention urgente avec offres promotionnelles ciblees.*

Validation naturelle du clustering : Le modele est **non supervise** – il ne voit pas le churn pendant l'entrainement. Pourtant, il identifie naturellement les meilleurs clients (Cluster 0) avec le churn le plus bas. Cela valide la qualite et la coherence du clustering.

4.3 Regression – Prediction des Depenses Futures

4.3.1 Configuration et preparation

```
REG_FEATURES = [
    'Frequency', 'TotalQuantity', 'AvgDaysBetweenPurchases',
    'UniqueProducts', 'TotalTransactions', 'SupportTicketsCount',
    'SatisfactionScore', 'Age',
    'MonetaryAvg',                # ajout v2
    'AvgQuantityPerTransaction',  # ajout v2
    'NegativeQuantityCount',      # ajout v2
    'CancelledTransactions'       # ajout v2
]  # 12 features au total

# Filtrage outliers MonetaryTotal (percentile 5% - 95%)
# Plus strict que 1%-99% pour meilleures performances
Q1_r, Q3_r = df_reg[REG_TARGET].quantile([0.05, 0.95])
df_reg = df_reg[(df_reg[REG_TARGET] >= Q1_r) &
                (df_reg[REG_TARGET] <= Q3_r)]
# 3934 lignes conservees sur 4372 (438 outliers retires)

reg_model = RandomForestRegressor(
    n_estimators=800,       # plus d'arbres = plus stable
    max_depth=25,
    min_samples_split=3,
    min_samples_leaf=1,
    max_features='sqrt',
    random_state=42, n_jobs=-1
)
reg_model.fit(X_reg_tr_s, y_reg_tr)

y_reg_pred = reg_model.predict(X_reg_te_s)
# Contrainte metier : la depense est toujours positive ou nulle
y_reg_pred = np.maximum(0, y_reg_pred)
```

Listing 14 – Configuration regression avec 12 features

4.3.2 Resultats de la regression

Metrique	Valeur	% erreur	Seuil	Evaluation
MAE	**153.07 £**	**13.6%**	$< 20\%$	**Excellent**
RMSE	**306.14 £**	**27.1%**	$< 40\%$	**Tres bon**
$\mathbf{R^2}$	**0.9304**	**93% explique**	> 0.80	**Excellent**

Depense moyenne du dataset test : 1129.51 £

- **MAE = 153£ (13.6%) :** En moyenne, le modele se trompe de ±153£sur une depense moyenne de 1129£. Tres precis.
- **RMSE = 306£ (27.1%) :** Plus eleve que la MAE car il penalise les grandes erreurs au carre. Les clients VIP (client 12748 = 4515£) creent des erreurs ponctuelles importantes – inevitable sur donnees retail.
- $\mathbf{R^2}$ **= 0.9304 :** Le modele explique **93% de la variance** des depenses. Seulement 7% reste inexplique. Excellent pour des donnees e-commerce naturellement bruitees.

Ameliorations apportees par rapport a la version initiale :

- Ajout de 4 features : MonetaryAvg, AvgQuantityPerTransaction, NegativeQuantityCount, CancelledTransactions
- Filtrage outliers plus strict : percentile 5%-95% au lieu de 1%-99%

— Augmentation n_estimators : 200 → 800
— Resultat : MAE passe de 375£ (28.2%) a **153£ (13.6%)**
— R^2 passe de 0.839 a **0.9304**

5 Deploiement – Application Flask

5.1 Architecture de l'API REST

Flask est un micro-framework Python leger et flexible, ideal pour creer des API REST servant des modeles ML. Il permet d'exposer nos modeles via des routes HTTP simples.

L'application expose **4 routes principales** :

Route	Methode	Fonctionnement
`/`	GET	Interface HTML – formulaire client interactif
`/random_client`	GET	Pioche un client aleatoire depuis data.csv et pre-remplit le formulaire
`/predict`	POST	Recoit JSON client → retourne churn + cluster + depense
`/verify/{id}`	GET	Compare prediction au vrai churn dans la base (validation)

5.2 11 Artefacts – Pattern Singleton

Les 11 artefacts sont charges **une seule fois au demarrage**. Sans ce pattern, chaque requete chargerait 11 fichiers pkl, ajoutant plusieurs secondes de latence.

```python
_model = None  # None = pas encore charge

def load_artifacts():
    global _model, _scaler, _knn_age, _kmeans, _pca_cluster
    global _reg_model, _scaler_reg, _feature_names
    global _country_means, _impute_values, _reg_features

    if _model is not None:  # Deja charge -- ne recharge pas
        return

    _model         = joblib.load(MODEL_PATH)
    _scaler        = joblib.load(SCALER_PATH)
    _knn_age       = joblib.load(KNN_AGE_PATH)
    _kmeans        = joblib.load(KMEANS_PATH)
    _pca_cluster   = joblib.load(PCA_CLUSTER_PATH)
    _reg_model     = joblib.load(REG_MODEL_PATH)
    _scaler_reg    = joblib.load(SCALER_REG_PATH)
    _feature_names = joblib.load(FEATURES_PATH)
    _country_means = joblib.load(CM_PATH)
    _impute_values = joblib.load(IMPUTE_PATH)
    _reg_features  = joblib.load(REG_FEATURES_PATH)
```

Listing 15 – Pattern Singleton pour le chargement

Artefact	Role
model.pkl	RandomForestClassifier entraine (211 arbres)
scaler.pkl	StandardScaler pour la classification (37 features)
features.pkl	Liste ordonnee des 37 features de classification
country_means.pkl	Target encoding des 37+ pays
impute_values.pkl	Medianes d'imputation (39 colonnes)
knn_age.pkl	KNN Imputer pour la variable Age (k=5)
kmeans.pkl	KMeans k=3 pour le clustering
pca_cluster.pkl	PCA 19 composantes pour le clustering
reg_model.pkl	RandomForestRegressor (800 arbres)
scaler_reg.pkl	StandardScaler pour la regression (12 features)
reg_features.pkl	Liste des 12 features de regression

5.3 Pipeline d'inference – 6 etapes

Les 6 etapes du pipeline /predict

1. **Reception JSON** → transform_for_inference() applique exactement le meme preprocessing qu'a l'entrainement (nettoyage, KNN Age, feature engineering, encodage, anti-leakage).
2. **Normalisation** → scaler.transform() – StandardScaler fitte sur X_train.
3. **Classification** → model.predict() + predict_proba() → churn_pred (0/1) + churn_proba (0.0–1.0) + risk_level (Faible/Moyen/Eleve/Critique).
4. **Clustering** → pca_cluster.transform() + kmeans.predict() → cluster (0/1/2) + cluster_label.
5. **Regression** → scaler_reg.transform() + reg_model.predict() → monetary_pred (depense estimee en £).
6. **Reponse JSON** contenant les 3 resultats en une seule requete.

```python
def risk_label(p: float) -> str:
    if   p < 0.20: return "Faible"
    elif p < 0.40: return "Moyen"
    elif p < 0.70: return "Eleve"
    else:          return "Critique"
```

Listing 16 – Niveaux de risque bases sur la probabilite

6 Resultats et Analyse Finale

6.1 Resume des performances

Metrique	Valeur finale	Seuil	Evaluation
Classification (Random Forest + Optuna)			
Accuracy	**80.57%**	> 80%	Excellent
AUC-ROC	**0.8558**	> 0.80	Tres bon
F1 Churn	**0.70**	> 0.70	Bon
F1 CV-5	**0.6835**	> 0.65	Bon
Stabilite	**±0.0052**	< ±0.02	Tres stable
Clustering (PCA 19 composantes + KMeans k=3)			
Segments identifies	**3 distincts**	–	Coherents
Variance PCA	**90.1%**	> 80%	Excellent
Outliers retires	**262**	–	Propre
Ecart churn clusters	**10.7%**	> 10%	Discriminant
Regression (Random Forest – 12 features)			
R^2	**0.9304**	> 0.80	Excellent
MAE	**153£ (13.6%)**	< 20%	Excellent
RMSE	**306£ (27.1%)**	< 40%	Tres bon

6.2 Predictions sur 10 clients reels

CustomerII	Churn	Probabilite	Risque	Cluster	Depense prevue
15484	0	14.64%	Faible	0	3 619.03 £
16952	1	87.00%	Critique	1	182.55 £
15745	0	8.74%	Faible	1	1 042.55 £
13570	1	58.64%	Eleve	0	281.17 £
13747	1	95.42%	Critique	1	230.47 £
12604	0	25.49%	Moyen	1	269.25 £
15054	0	18.01%	Faible	0	339.77 £
12999	1	66.92%	Eleve	1	517.96 £
13149	0	15.22%	Faible	1	1 793.55 £
12748	0	2.69%	Faible	0	4 515.21 £
Resume : 4/10 churners predits | Probabilite moy. : 39.28% | Depense moy. : 1 279.15 £					

Observations cles :

— Le client **13747** a 95.42% de churn mais depense prevue 230£– action de retention : cout vs revenu a evaluer.

— Le client **12748** est fidele (2.69%) avec depense prevue **4515£** – client VIP a conserver absolument.

— Le client **16952** : 87% churn + 182£depense – retention ciblee recommandee.

7 Conclusion et Perspectives

7.1 Bilan du projet

Ce projet a permis de developper une solution Machine Learning complete couvrant l'integralite de la chaine de traitement data science, depuis l'exploration des donnees brutes jusqu'au deploiement d'une API Flask fonctionnelle.

7.2 Points forts

- **Pipeline rigoureux :** Preprocessing → Modelisation → Deploiement sans data leakage, reproductibilite garantie (seed=42 partout).
- **Approche multi-modeles :** Classification + Clustering + Regression – vision a 360 degres du client.
- **Imputation avancee :** KNN Imputer pour Age (30% de NaN), mediane robuste pour 39 colonnes.
- **Anti-leakage rigoureux :** 40 colonnes supprimees. Sans cette etape : accuracy artificielle de 99%.
- **Resultats excellents :** AUC-ROC = 0.856, R^2 = 0.9304 – performances au-dessus des seuils industriels.
- **Stabilite exceptionnelle :** F1 CV-5 = 0.6835 ± 0.0052 – absence totale d'overfitting.
- **Deploiement complet :** API Flask 4 routes, 11 artefacts, pipeline inference 6 etapes, interface HTML interactive avec verification en temps reel.

7.3 Limites

- **F1 Churn = 0.70 :** 95 churners manques sur 291 (faux negatifs).
- **Dataset limite :** 4372 clients suffisant pour Random Forest mais insuffisant pour Deep Learning.
- **Multicolinearite residuelle :** RegYear VIF = 840 – conserve car feature temporelle utile.

7.4 Perspectives

Amelioration	Impact attendu
XGBoost / LightGBM	Algorithmes souvent plus performants sur donnees tabulaires.
Ajustement du seuil	Passer de 0.5 a 0.4 pour reduire les faux negatifs (churners manques).
Enrichissement donnees	Ajouter features temporelles pour capturer l'evolution comportementale.
Deep Learning	Explorer reseaux neurones avec dataset plus grand (> 50k clients).
Monitoring en production	Detecter le data drift et reentrainer periodiquement.
Deploiement Cloud	Migrer API Flask vers AWS/Azure pour scalabilite.

Resume Final du Projet

Pipeline ML complet – 11 artefacts – API Flask – Predictions en temps reel

80.57%	**0.8558**	**0.9304**	**3 segments**
Accuracy	AUC-ROC	R^2	Clustering

153£ (13.6%)	**306£ (27.1%)**	**0.683 ± 0.005**
MAE Regression	RMSE Regression	F1 CV-5

4372 clients | 52 features brutes → 37 propres | PCA 19 composantes | KMeans k=3